



**PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ
PRÓ-REITORIA DE PESQUISA, PÓS-GRADUAÇÃO E
INOVAÇÃO**

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO CIENTÍFICA – PIBIC

RELATÓRIO PARCIAL

**ABORDAGENS DEEP LEARNING PARA MITIGAÇÃO DE
ATAQUES POR REPLAY EM SISTEMAS DE AUTENTICAÇÃO
BIOMÉTRICA**

**CURITIBA
2026**

Henrique Poledna

CiberSegurança

Pontifícia Universidade Católica do Paraná

Câmpus Curitiba

**ABORDAGENS DEEP LEARNING PARA MITIGAÇÃO DE
ATAQUES POR REPLAY EM SISTEMAS DE AUTENTICAÇÃO
BIOMÉTRICA**

Relatório Parcial apresentado à Pontifícia
Universidade Católica do Paraná, Pró-
Reitoria de Pesquisa, Pós-Graduação e
Inovação, Programa Institucional de Bolsas
de Iniciação Científica e Tecnológica, sob
orientação de PROF. ANDRÉ GUSTAVO
HOCHULI

**CURITIBA
2026**

SUMÁRIO

1 INTRODUÇÃO.....	2
2 OBJETIVO(S).....	3
3 MATERIAL E MÉTODOS.....	3
3.1 O DESAFIO ASVSPOOF.....	4
3.2 DESCRIÇÃO DA BASE DE DADOS (PA).....	4
3.3 ESTRUTURA E DISTRIBUIÇÃO DOS DADOS.....	5
3.4 PROCESSAMENTO DE DADOS E EXTRAÇÃO DE CARACTERÍSTICAS.....	6
3.5 ARQUITETURA DO MODELO E TREINAMENTO.....	7
4 RESULTADOS PARCIAIS.....	8
4.1 PROBLEMAS NA EXTRAÇÃO DE ESPECTROGRAMAS E CORREÇÃO DE FRAMES.....	8
4.2 DESEMPENHO E MÉTRICAS DE EER.....	9
4.3 CONCLUSÃO DA ETAPA.....	10
5 ETAPAS FUTURAS.....	10
6 RELATO DE EXPERIÊNCIA.....	11
7 USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA.....	11
8 REFERÊNCIAS.....	13

1 INTRODUÇÃO

A digitalização de serviços essenciais e o controle de dispositivos inteligentes por smartphones consolidaram a biometria de voz como um mecanismo relevante de autenticação. Entretanto, essa popularização ampliou vulnerabilidades, especialmente os ataques de spoofing. Entre eles destaca-se o Audio Replay Attack, no qual um invasor utiliza dispositivos de gravação e reprodução para simular a voz de um usuário legítimo. O desafio tecnológico consiste em distinguir o sinal de voz original daquele reproduzido, que apresenta distorções acústicas introduzidas pelo dispositivo e pelo ambiente.

No campo do aprendizado de máquina, as contramedidas evoluíram de modelos estatísticos para arquiteturas de Deep Learning, que utilizam espectrogramas para extrair padrões espaciais e temporais do sinal. Estudos recentes, como o de Dişken (2024), indicam que a análise de energias regionais e de artefatos em segmentos de silêncio pode reduzir significativamente a taxa de erro (EER). Além disso, o estado da arte inclui redes convolucionais profundas, como a ResNet41, e modelos baseados em Transformers, capazes de identificar inconsistências fonéticas associadas a fala reproduzida ou sintética. A validação em bases como ASVspoof 2019/2021 é essencial para garantir a generalização desses modelos.

A relevância desta pesquisa está na necessidade de mitigar fraudes biométricas com impactos socioeconômicos significativos. Estima-se que, em 2024, 49% das empresas já tenham enfrentado incidentes envolvendo deepfakes de áudio ou vídeo. Nesse contexto, o desenvolvimento de contramedidas baseadas em Machine Learning para análise de sinais acústicos complexos torna-se fundamental para aumentar a confiabilidade de sistemas de autenticação em setores críticos, como o financeiro e o governamental.

2 OBJETIVO(S)

Esta pesquisa parte da hipótese de que a integração de múltiplas representações espectrais, combinada a técnicas de deep learning e modelos pré-treinados, pode gerar contramedidas mais precisas e robustas para a detecção de Audio Replay Attacks, superando limitações de métodos tradicionais baseados em características manuais. Assim, o objetivo geral é desenvolver e avaliar modelos de aprendizado profundo capazes de detectar ataques de reprodução de áudio, aumentando a segurança de sistemas de autenticação biométrica por voz.

Para isso, o projeto investiga abordagens de deep learning voltadas à detecção de spoofing, com foco em ataques de reprodução, propondo arquiteturas capazes de extrair características discriminativas entre vozes genuínas e reproduzidas. Serão avaliadas diferentes representações do sinal de áudio e estratégias de integração com modelos pré-treinados, visando capturar nuances acústicas associadas à reprodução. Os modelos serão validados por meio de análises comparativas utilizando bases amplamente adotadas na literatura, como ASVspoof 2019 e 2021, buscando desenvolver contramedidas robustas e com boa capacidade de generalização para cenários reais.

3 MATERIAL E MÉTODOS

Esta pesquisa adota uma abordagem experimental quantitativa, focada no desenvolvimento e avaliação de modelos de Deep Learning para a detecção de ataques de reprodução de áudio. O material base utilizado é o banco de dados ASVspoof 2019, especificamente a partição de Physical Access (PA).

3.1 O DESAFIO ASVSPOOF

O Automatic Speaker Verification Spoofing and Countermeasures Challenge (ASVspoof) é uma iniciativa internacional que visa fomentar o desenvolvimento de contramedidas contra ataques biométricos de voz. A edição de 2019 introduziu cenários mais complexos, dividindo os ataques em Acesso Lógico (LA) — focado em síntese de voz e conversão de voz — e Acesso Físico (PA), que é o foco deste trabalho.

3.2 DESCRIÇÃO DA BASE DE DADOS (PA)




Figura 1: Exemplo de cenário de acesso físico.

Diferente dos ataques digitais, o cenário de Acesso Físico (PA) simula ataques de replay, mostrado na figura 1, onde uma gravação de voz legítima é reproduzida em um ambiente físico por um dispositivo de ataque (alto-falante) e capturada pelo microfone do sistema de autenticação.

Como a base foi construída: A base PA foi gerada através de simulações acústicas extensivas, utilizando:

- 1) 27 configurações de ambiente: Variações no tamanho da sala e nos níveis de reverberação.

2) 9 configurações de dispositivos de reprodução: Simulação de diferentes qualidades de alto-falantes (desde dispositivos de baixa fidelidade até sistemas de alta qualidade).

3) Geometria de gravação: Diferentes distâncias e ângulos entre o atacante, o alto-falante e o sistema de defesa.

O resultado é um conjunto de dados que não testa apenas a detecção do ataque em si, mas a capacidade do modelo de distinguir as características da voz humana das distorções causadas pelo ambiente físico e pelo hardware de reprodução.

3.3 ESTRUTURA E DISTRIBUIÇÃO DOS DADOS

Abaixo, apresentam-se os números de áudios e a distribuição das amostras entre vozes legítimas (Bonafide) e ataques (Spoof) para as três partições do dataset:

Partição	Bonafide	Spoof (Replay)	Total
Treino (Train)	5400	48600	54000
Desenvolvimento (Dev)	5400	24300	29700
Avaliação (Eval)	18090	116640	134730

Tabela 1: Número de áudios

Detalhamento dos ataques (PA): Os ataques de replay são categorizados por níveis de dificuldade baseados no ambiente e nos dispositivos. Salas menores com menos reverberação e dispositivos de alta qualidade representam os ataques mais sofisticados, pois as pistas acústicas do "ambiente de ataque" são mais sutis e difíceis de detectar pela contramedida.

3.4 PROCESSAMENTO DE DADOS E EXTRAÇÃO DE CARACTERÍSTICAS

A etapa inicial, já concluída, consistiu na transformação sistemática de todos os arquivos de áudio (formato .flac) em representações visuais espectro-temporais para processamento por visão computacional. Utilizando a biblioteca Librosa e ferramentas de automação em Python, cada amostra de áudio foi convertida em cinco tipos distintos de imagens (espectrogramas), permitindo uma análise multicritério do sinal.

A Figura 2 apresenta exemplos dessas representações, juntamente com a descrição de cada.




Figura 2: Exemplo de espectrogramas.

2.a) STFT (Short-Time Fourier Transform): Para análise de frequência linear.

2.b) Log-Mel Spectrogram: Para representação em escala mel, aproximando-se da percepção auditiva humana.

2.c) CQT (Constant-Q Transform): Para melhor resolução em frequências baixas.

2.d,2.e) LFCC e CQCC: Coeficientes cepstrais otimizados para a identificação de artefatos de spoofing.

3.5 ARQUITETURA DO MODELO E TREINAMENTO

Para a classificação entre áudios genuínos (bonafide) e falsificados (spoof), foi utilizada uma arquitetura baseada na rede neural convolucional EfficientNet-B0, implementada no framework PyTorch. O modelo foi adaptado para processar espectrogramas de canal único e configurado para classificação binária na camada de saída.




Figura 3: Arquitetura simplificada da rede EfficientNet-B0.

A EfficientNet-B0 utiliza o princípio de compound scaling, que equilibra profundidade, largura e resolução da rede para melhorar a eficiência computacional. Sua arquitetura, ilustrada na Figura 3, é composta por uma camada convolucional inicial (stem), seguida por múltiplos blocos MBConv (Mobile Inverted Bottleneck Convolution) com mecanismos de Squeeze-and-Excitation, responsáveis por extrair representações discriminativas dos espectrogramas. Ao final da rede, aplica-se Global Average Pooling, seguido de uma camada totalmente conectada para realizar a classificação final entre bonafide e spoof.

Durante o treinamento, foram adotadas as seguintes estratégias:

- 1) Early Stopping: interrupção automática caso não haja melhoria na Taxa de Erro Igual (EER) após 10 épocas.
- 2) Validação Cruzada: utilização das partições de treino, desenvolvimento (dev) e avaliação (eval) do conjunto ASVspoof 2019.
- 3) Métricas de Desempenho: avaliação baseada na Equal Error Rate (EER), além da análise de matriz de confusão e métricas de classificação (precisão, recall e F1-score).

O projeto utiliza bases de dados públicas, anonimizadas e amplamente reconhecidas pela comunidade científica.

4 RESULTADOS PARCIAIS

A pesquisa encontra-se em fase avançada, com a conclusão dos testes em cinco frentes de extração de características para o dataset ASVspoof 2019 Physical Access (PA). O foco central desta etapa foi a análise do EER (Equal Error Rate), métrica que define a precisão do sistema em distinguir vozes reais de ataques simulados.

4.1 PROBLEMAS NA EXTRAÇÃO DE ESPECTROGRAMAS E CORREÇÃO DE FRAMES

Durante a implementação, identificou-se que as funções padrão de processamento falhavam em 80% das amostras do conjunto PA. O erro ocorre porque os ataques de spoofing do dataset foram gerados por algoritmos antigos que corrompem a estrutura dos arquivos FLAC, causando a perda de frames e inconsistências nos metadados.

Enquanto as ferramentas convencionais interrompem a execução ao encontrar esses arquivos malformados, foi desenvolvida uma abordagem que realiza a leitura direta dos dados brutos, ignorando os erros de cabeçalho e reconstruindo a sequência de frames de forma absoluta. Esse ajuste garantiu a integridade necessária para que 100% da base pudesse ser convertida em espectrogramas para o treinamento.

4.2 DESEMPENHO E MÉTRICAS DE EER

Modelo	EER (%)	Acurácia (%)	F1-Score (Bonafide)
Log-Mel	1,54	98,46	0,95
STFT	1,7	98,3	0,94
CQT	1,97	98,03	0,93
CQCC	2,92	97,07	0,9
LFCC	5,36	94,64	0,83

Tabela 2 – Desempenho dos modelos avaliados na base ASVspoof 2019 PA.

Os resultados apresentados na Tabela 2 correspondem ao desempenho dos modelos avaliados com base no menor valor de Equal Error Rate (EER) obtido durante o treinamento no conjunto de desenvolvimento (DEV), sendo posteriormente analisados no conjunto de avaliação (EVAL) da base ASVspoof 2019 PA.

O método CQT (Constant-Q Transform) apresentou o melhor desempenho no conjunto de desenvolvimento, atingindo um EER de 1,20% na época 11, com interrupção do treinamento na época 21 devido ao early stopping. No conjunto EVAL, obteve EER de 1,97% e acurácia de 98,03%, com F1-score de 0,93 para bonafide e 0,99 para spoof.

O Log-Mel Spectrogram alcançou EER de 1,34% no DEV (época 29), com término do treinamento na época 39. No conjunto EVAL, apresentou o melhor resultado geral, com EER de 1,54% e acurácia de 98,46%, além de F1-score de 0,95 para bonafide e 0,99 para spoof, indicando melhor capacidade de generalização.

O STFT (Short-Time Fourier Transform) registrou EER de 1,61% no DEV (época 17), com encerramento do treinamento na época 27. No EVAL, obteve EER de 1,70% e acurácia de 98,30%, demonstrando desempenho equilibrado entre as classes.

A técnica CQCC (Constant Q Cepstral Coefficients) apresentou EER de 1,63% no DEV. No conjunto EVAL, obteve EER de 2,92% e acurácia de 97,07%, com aumento no número de falsos negativos.

Por fim, o LFCC (Linear Frequency Cepstral Coefficients) apresentou maior dificuldade de convergência, obtendo EER de 4,96% no DEV. No EVAL, registrou EER de 5,36% e acurácia de 94,64%, sendo o modelo com pior desempenho geral.

De forma geral, observa-se que representações espectrais completas (CQT, Log-Mel e STFT) apresentaram desempenho superior às abordagens baseadas exclusivamente em coeficientes cepstrais (CQCC e LFCC), especialmente no conjunto de avaliação final.

4.3 CONCLUSÃO DA ETAPA

A técnica CQT se destacou como a mais promissora para a detecção de spoofing em ambientes físicos. Com a superação dos erros de processamento dos arquivos FLAC, todos os arquivos de scores finais para o conjunto de avaliação (EVAL) já foram gerados.

5 ETAPAS FUTURAS

O cronograma de atividades permanece adequado ao tempo disponível para a conclusão do projeto.

As próximas atividades focam na implementação da métrica t-DCF (tandem Detection Cost Function). Esta análise é indispensável para validar a eficácia da contramedida em um cenário de uso real, operando em conjunto com sistemas de verificação automática de locutor (ASV), conforme os padrões estabelecidos nos benchmarks ASVSpooof 2019 e 2021.

Na sequência, serão desenvolvidas as estratégias de Ensemble previstas na etapa 4. O objetivo é realizar a concatenação de características e a combinação dos modelos que apresentaram melhor desempenho individual, visando aumentar a robustez do sistema contra a variabilidade dos dispositivos de reprodução. Além disso, seguindo os objetivos específicos, o projeto passará a explorar:

- 1) Modelos Pré-treinados: Integração de embeddings como x-vectors, ECAPA-TDNNs e wav2vec 2.0 para capturar características fonéticas mais complexas.
- 2) Modelos Generativos: Investigação do uso de AutoEncoders e GANs para melhorar a generalização contra ataques desconhecidos.

6 RELATO DE EXPERIÊNCIA

A experiência no PIBIC tem sido muito positiva, despertando um interesse real pela área e o desejo de continuar na pesquisa. Antes do projeto, meu conhecimento em Machine Learning era zero, mas o desenvolvimento me permitiu entender como a visão computacional funciona na prática. Foi muito interessante aprender que áudios podem ser transformados em imagens e que diferentes representações, capturam detalhes específicos que fazem toda a diferença na detecção de fraudes.

Além do salto técnico, o suporte do Prof. André tem sido fundamental. As orientações diretas e a expertise do orientador garantiram que eu saísse do zero para uma base sólida em Deep Learning, contribuindo de forma real para o avanço das contramedidas de áudio.

7 USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA

PERGUNTAS SOBRE O USO DE IA GENERATIVA
1) Para escrita deste relatório, alguma ferramenta de inteligência artificial generativa foi utilizada? Sim (X) Não (□)
2) Qual(is) ferramenta(s) de IA generativa você utilizou?

Não se aplica (☐)	Se sim, cite quais: gemini
--	----------------------------

3) Indique quais os usos de IA generativa foram aplicadas no neste relatório:

Não se aplica (☐)

Correção gramatical (ortografia e concordância) (X)

Formatação das referências (X)

Gerar partes do texto escrito (ex: frases, parágrafos, conceitos) (X)

Gerar a totalidade do texto escrito (☐)

Gerar citações (☐)

Criação/edição das imagens e gráficos (X)

Correção/auxílio na formatação final dos códigos estatísticos (ou outro software) (☐)

Outros usos – especificar:

4) Declaração do uso de qualquer ferramenta de IA:

Caso tenha utilizado IA:

X Durante a preparação deste Relatório Parcial, o(s) autor(es) usaram Gemini 1.5 Pro para correção ortográfica, ajuste de harmonia e coesão textual, além da formatação das referências bibliográficas conforme as normas exigidas. Após usar essa ferramenta, o(s) autor(es) revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo.

OU

Caso NÃO tenha utilizado IA:

☐ Durante a preparação deste Relatório Parcial, o(s) autor(es) afirmam que não utilizaram nenhuma inteligência artificial (IA).

8 REFERÊNCIAS

ALAN V. OPPENHEIM. Spectrogram and the STFT. Aalto University. Disponível em: https://speechprocessingbook.aalto.fi/Representations/Spectrogram_and_the_STFT.html. Acesso em: 2026.

CHAKRAVARTY, Nidhi; DUA, Mohit. Publicly available datasets analysis and spectrogram-ResNet41 based improved features extraction for audio spoof attack detection. International Journal of System Assurance Engineering and Management, v. 15, n. 12, p. 5611–5636, dez. 2024. Disponível em: <https://doi.org/10.1007/s13198-024-02550-1>. Acesso em: 2026.

CUCCOVILLO, Luca; GERHARDT, Milica; AICHROTH, Patrick. Audio Spectrogram Transformer for Synthetic Speech Detection via Speech Formant Analysis. In: 2023 IEEE International Workshop on Information Forensics and Security (WIFS). Ilmenau, Alemanha: IEEE, 2023. p. 1-6. Disponível em: <https://doi.org/10.1109/WIFS58808.2023.10374615>. Acesso em: 2025.

DIŞKEN, Gökay. Complementary regional energy features for spoofed speech detection. Computer Speech & Language, v. 84, 101602, mar. 2024. Disponível em: <https://doi.org/10.1016/j.csl.2023.101602>. Acesso em: 2025

KINNUNEN, Tomi et al. ASVspoof 2019: Selected Topics in Antispoofing for Speaker Recognition. arXiv preprint arXiv:1904.05441, 2019. Disponível em: <https://arxiv.org/abs/1904.05441>. Acesso em: 2025.

TODISCO, Massimiliano et al. ASVspoof 2019: Future Horizons in Spoofed and Fake Audio Detection. In: Proc. Interspeech 2019. Graz, Áustria, 2019. p. 1008-1012. Disponível em: <https://www.asvspoof.org/asvspoof2019/interspeech2019.pdf>. Acesso em: 2026.

HOCHULI, André Gustavo. Abordagens Deep Learning para Mitigação de Ataques por Replay em Sistemas de Autenticação Biométrica. Projeto de Pesquisa (PIBIC - Vigência 2025/2026) - Pontifícia Universidade Católica do Paraná, Curitiba, 2025.

ALI, Hassan et al. A fine tuned EfficientNet-B0 convolutional neural network for accurate and efficient classification of apple leaf diseases. Scientific Reports, v. 15, n. 25732, p. 1-26, jan. 2025. Disponível em: <https://www.nature.com/articles/s41598-025-04479-2>. Acesso em: 4 mar. 2026.

SUNG, Boo. EfficientNet Implementation. Substack: Boo's Tech Journal, 2024. Disponível em: <https://boosung.substack.com/p/efficientnet-implementation>. Acesso em: 4 mar. 2026.