


ASVspoof 2019

ASVspoof 2019 representa um avanço significativo em relação às suas edições anteriores (2013, 2015 e 2017) na luta contra ataques de falsificação (spoofing) em sistemas de Verificação Automática de Locutor (ASV)


Enquanto as edições passadas focavam em áreas específicas o desafio 2015 abordou primeiramente ataques de Síntese de Fala (SS) e Conversão de Voz (VC), e o 2017 concentrou-se nos ataques de Replay (reprodução) com uma metodologia menos controlada a edição 2019 amplia o escopo.

ASVspoof 2019 é o primeiro a focar simultaneamente em todos os três principais vetores de ataque (SS, VC e Replay)

Simulação



O dataset de treinamento explora a defesa contra 27 configurações acústicas diferentes (variando tamanho da sala, reverberação e distância e 9 configurações de replay (variando distância de captura D e qualidade do alto-falante).



Gravação (IR Recording): O som é capturado com a acústica da sala da distância do atacante (D_a)

Dispositivo (IRs Device): O som ganha as distorções não lineares do alto-falante de replay (qualidade Q).

Reprodução (IR Replay): O som distorcido é, então, retransmitido com a reverberação da sala do ASV (D_s)

Função de Custo de Detecção em Tandem (t-DCF)

$$t\text{-DCF}(s) = C_1 P_{\text{miss}}^{\text{cm}}(s) + C_2 P_{\text{fa}}^{\text{cm}}(s),$$

Custo Total = (Chance de Atrasar o Legítimo x 1) + (Chance de Deixar o Fraudador Passar x 10)

Função de Custo de Detecção em Tandem (t-DCF)

A normalização é o processo de pegar o seu Custo Básico (t-DCF) e transformá-lo em uma nota ou índice de desempenho

$$\text{t-DCF}_{\text{norm}}(s) = \beta P_{\text{miss}}^{\text{cm}}(s) + P_{\text{fa}}^{\text{cm}}(s),$$

Normalizar = É como transformar a nota bruta de uma prova (Ex: 85 pontos) em uma nota relativa (Ex: está 20% acima da média)

Agora temos que normalizar o resultado da Equação (1) para torná-lo comparável e significativo

Por que fazemos?

Porque o -tDCF básico é apenas um número grande (C1 e C2 têm muitos componentes). Normalizar torna o resultado fácil de entender

Função de Custo de Detecção em Tandem (t-DCF)

$$t\text{-DCF}_{\text{norm}}^{\text{min}} = t\text{-DCF}_{\text{norm}}(s_*),$$

O objetivo da Minimização é garantir que o seu sistema seja avaliado pelo seu melhor desempenho possível, e não por uma configuração ruim ou aleatória.

Você testa todas as posições do botão (s)

Você anota o custo normalizado (t-DCF_{norm}) para cada posição.

Você seleciona o menor valor de custo que você registrou


espectrogramas

STFT Espectrograma

Espectrograma clássico.


Mostra tempo × frequência com intensidade em cores.

Para quê: visão geral do áudio, ruídos.




Mel-Espectrograma

Frequências convertidas para escala Mel (mais “humana”).
Para quê: fala, IA, reconhecimento de áudio.



Log-Mel Espectrograma


Mel com energia em escala log - mais contraste.
Para quê: Deep Learning (classificação).



Cochleagrama (CQT)


Frequências distribuídas como no ouvido/cóclea.

Para quê: música, notas, harmônicos.




Log-STFT

**STFT com eixo de frequência em escala log.
Para quê: voz, fala, formantes mais claros.**



Chroma

**Agrupa frequências por nota musical (C, C#, D...).
Para quê: acordes, harmonia, análise tonal.**



Gabor

**STFT com janela Gaussiana - espectro mais limpo.
Para quê: eventos curtos, pesquisa, análise refinada**

